Практическая ценность проекта

Коротко

Мы прогнозируем для каждого района Лондона на ближайшие месяцы два показателя:

- **медианную цену продажи жилья**;
- **число продаж жилья**.

Прогноз строится только по открытым данным: история сделок, характеристики домов, преступность в районе, ставки и ипотека в Великобритании.

Кому это может быть полезно

> Это наша гипотеза: мы не опрашивали инвесторов.

Тем, кто покупает жильё в Лондоне как вложение, но плохо знает город:

- **фондам**, которые вкладывают деньги в жилую недвижимость;
- **частным инвесторам**, которые покупают квартиру, чтобы она выросла в цене.

Какую задачу решает проект

Вопрос инвестора: *в каких районах цены, скорее всего, будут расти, а в каких падать, и где активно покупают жильё?*

Чтобы ответить самому, нужно собрать данные из нескольких источников, свести их по районам и построить прогноз. Проект делает это и показывает результат в одном месте.

Что показывает прогноз и чего не показывает

Показатель	Что значит	Чего не значит
Медианная цена	Половина жилья в районе за месяц продана дешевле этой цены, половина дороже	Это не доходность конкретной квартиры. Медиана может вырасти просто потому, что в этом месяце продали больше дорогих домов
Число продаж	Насколько активно в районе покупают жильё	Это не то, как быстро получится продать конкретную квартиру

Как это можно использовать

1. **Сравнить районы.** Посмотреть, где прогнозируется рост медианной цены, а где падение.
2. **Следить за районом.** Обновлять прогноз, когда выходят новые данные, и смотреть, не меняется ли тренд.

Это помощь на первом шаге, чтобы сократить список районов. Перед покупкой всё равно нужно отдельно проверять конкретный объект.

Насколько реально это внедрить

Что помогает

- **Все данные открытые.** Источники распространяются по лицензии Open Government License.
- **Данные регулярно обновляются.** Сделки, преступность и данные Банка Англии выходят помесячно.
- **Не нужна дорогая инфраструктура.** Модели работают на табличных данных.

Трудности

Проблема	Насколько серьёзно	Что делаем
Резкие изменения рынка. Пандемия 2020 года, рост ставок по ипотеке в 2022 году. Модель, обученная на прошлом, в такие периоды может сильно ошибаться	Высокая	Регулярно переобучаем модель, отдельно проверяем качество на этих периодах
Задержка данных. Сделки попадают в реестр с опозданием, поэтому последние месяцы неполные	Средняя	Учитываем это при подготовке данных
Мало данных. 33 района и помесячные ряды	Средняя	Начинаем с простых моделей и сравниваем их с простыми прогнозами
Мало фичей. Некоторые признаки (новости и данные об аренде) не получилось добавить на данном этапе	Средняя	Собираем модель и тестируем точность и описательную силу на тех фичах, которые можем достать сейчас
Медиана зависит от того, что продали. Если в месяце продали больше дорогих домов, медиана вырастет без реального роста цен	Средняя	Объясняем пользователю, что показывает медиана. Характеристики домов из энергосертификатов частично помогают это учесть

Как оценить качество

Модель учится на прошлом, а проверяется на более поздних месяцах, которых она не видела.

1. **Средняя ошибка.** На сколько фунтов в среднем ошибается прогноз цены и на сколько сделок прогноз числа продаж (MAE). То же самое в процентах (MAPE).
2. **Сравнение с простыми прогнозами.** «Как в прошлом месяце» и «как в этом же месяце год назад». Если модель не лучше, она не нужна.
3. **Направление.** Правильно ли модель угадывает, вырастет показатель или упадёт.
4. **Порядок районов.** Совпадает ли порядок районов по прогнозному изменению цены с фактическим.
5. **Сложные периоды.** Отдельно смотрим ошибку в 2020 и 2022 годах.

Учебная ценность

Для команды это главный результат проекта.

- **Полный цикл ML-проекта.** Сбор данных → база данных → датасет → разведочный анализ → линейные модели → нелинейные модели → сервис → DL.
- **Реальные данные со всеми проблемами.** Пропуски, задержки, разная география в разных источниках, проверка лицензий.
- **Открытый датасет.** Помесячные данные по районам Лондона из нескольких источников, сведённые в одну таблицу. Может пригодиться другим.

Что мы не проверяли

Это гипотезы, а не доказанные факты:

- что инвесторам действительно нужен такой прогноз;
- что наша модель будет точнее простых прогнозов;
- насколько наш сервис лучше или хуже платной аналитики: мы её не сравнивали.